

Klasyfikacja fake-news

Sieć neuronowa TF-IDF → MLP (od zera w PyTorchu)

Aleksander Oleszkiewicz

Sztuczne Sieci Neuronowe — projekt

Problem

- **Zadanie:** klasyfikacja binarna artykułów prasowych — *Real vs Fake*.
- **Konwencja:** 1 = Real , 0 = Fake .
- Zbiór *Fake and Real News* (Kaggle), ~45 tys. artykułów po angielsku.

Prawdziwa trudność nie leży w modelu, lecz w danych.

Zbiór jest pełen *wycieku informacji* — można uzyskać ~100% trafności nie ucząc się treści, tylko artefaktów technicznych.

Zbiór danych — pierwsze spojrzenie

- **44 898** artykułów, klasy niemal zrównoważone (~52% Fake / 48% Real).
- **~14% duplikatów** — niemal wyłącznie w klasie Fake.
- ~1,4% tekstów pustych (same odnośniki YouTube).
- Rozkład długości prawoskośny.
- **95. percentyl $\approx$ 900 słów** → kandydat na `max_seq_len` dla modelu sekwencyjnego.

Pułapka: data leakage

Informacja wzajemna (MI) demaskuje markery zdradzające klasę bez treści:

Marker	MI [nat]	Klasa
słowo „reuters”	0,650	Real
dateline „MIASTO (Reuters) –”	0,456	Real
„featured image”	0,136	Fake
@handle	0,076	Fake

- Kolumna `subject` rozdziela klasy **w 100%** → odrzucona.
- `title`, `date` też niosą wyciek → **model używa tylko kolumny `text`**.

Czyszczenie danych

Kaskada wyrażeń regularnych (`src/data/cleaning.py`) usuwa m.in.:
markery Reuters · URL-e · `@handle` · prefiksy clickbait · podpisy zdjęć (getty) ·
HTML · sygnatury serwisów → normalizacja + małe litery.

Filtr: `min_words = 10`

Efekt:

44 898 → **38 470** artykułów

- duplikaty: 13,9% → **0%**
- kluczowe markery: → **0%**
- pokrycie GloVe: $OOV \leq 0,2\%$

Podział **stratyfikowany** 60/20/20 → train 23 082 · val 7 694 · test 7 694.

Reprezentacja: TF-IDF

- Tekst → wektor **TF-IDF** (1-2-gramy, `max_features=50 000`, `min_df=5`, `sublinear_tf`).
- To **nieparametryczna inżynieria cech** — *nie* model pretrenowany.
→ sieć uczy się w całości **od zera**.
- Dopasowanie **tylko na train**; ten sam wektoryzator co baseline
→ uczciwe porównanie LogReg vs MLP.


Architektura MLP

TF-IDF (50 000) → Linear(50000, 256) → ReLU → Dropout(0.3) → Linear(256, 1) → logit

- Wyjście = **logit** (bez sigmoidy)
→ BCEWithLogitsLoss (stabilne numerycznie).
- **12 800 513** parametrów
(głównie pierwsza warstwa 50k × 256).
- Optymalizator: **Adam**, lr = 1e-3
- batch = 256, maks. 20 epok
- **early stopping** na F1 (walidacja),
patience = 3, przywracanie najlepszych wag

Trening: krzywe uczenia

Krzywe uczenia MLP



Sieć zbiega w pierwszych epokach; early stopping zatrzymał trening po **11 epokach**.

Wyniki na teście

Metryka	Walidacja	Test
accuracy	0,9908	0,9864
precision	0,9899	0,9838
recall	0,9934	0,9915
F1	0,9916	0,9877
ROC-AUC	0,9992	0,9987


Macierz pomyłek — zbiór testowy (MLP)

Prawdziwa klasa	Predykcja	
	Fake (0)	Real (1)
Fake (0)	3387	69
Real (1)	36	4202

Metryki ~0,99 — praktyczny **sufit jakości** tego zbioru.

Krzywa ROC


Krzywa ROC — zbiór testowy (MLP)



Pole pod krzywą (AUC) = 0,9987 — model niemal idealnie separuje klasy.

Diagnoza bias–variance

Krzywa uczenia — diagnoza bias/variance



- F1 treningowe $\approx 1,0 \rightarrow$ **niski bias**
- luka train–val $\sim 0,8$ pp i maleje $\rightarrow$ **niska wariancja**
- krzywa walidacji szybko na plateau

Wniosek: więcej danych ani większy model **nie pomogą** — jesteśmy przy suficie zbioru.

Baseline vs MLP

Metryka	LogReg	MLP
accuracy	0,9795	0,9864
F1	0,9815	0,9877
ROC-AUC	0,9970	0,9987

- MLP lepszy o **~0,6 pp F1** — różnica marginalna.
- Klasy niemal liniowo separowalne w TF-IDF → nieliniowość nie daje przewagi.
- **Wartość etapu:** zweryfikowana pętla treningowa PyTorch'a pod model docelowy.


Przykładowe predykcje

Fragment	Prawd.	P(Real)	Pred.	
„germany foreign minister said...”	Real	1,0000	Real	✓
„patrick henningsen the longer...”	Fake	0,0000	Fake	✓
„the washington post nearly third...”	Fake	0,9998	Real	✗
„- below are the highlights...”	Real	0,0015	Fake	✗

Błędy mają **czytelne przyczyny**: FP — styl agencyjny w tekście Fake; FN — format listy / tematyka rozrywkowa w tekście Real.

Interpretowalność cech

Najsilniejsze n-gramy wg współczynników regresji logistycznej



Wnioski i dalszy krok

- Pierwsza **sieć od zera** w projekcie: TF-IDF → MLP, F1/AUC ~0,99 na teście.
- Na tym zbiorze sieć dorównuje modelowi liniowemu — reżim **low bias / low variance**, sufit metryk.
- Zbudowana i zweryfikowana **pętla treningowa PyTorch**a: Adam, BCEWithLogitsLoss, early stopping, dropout, weight decay, GPU (ROCm).

Następny etap: BiLSTM + Attention z GloVe 300d — modelowanie kontekstu i **wyjaśnialność przez wagi atencji** na poziomie pojedynczego artykułu.

Dziękuję za uwagę

Pytania?